

Projet : Reconnaissance de panneaux de signalisation (GTSRB)

Date : 23 Mai 2026

Anas DAGGAG - Jeremy DOUBLET - APP5 EIE



Objectif

Ce projet vise à reconnaître automatiquement des panneaux de signalisation à partir d'images. L'objectif principal est d'obtenir une bonne précision de classification sur le jeu de données GTSRB, et de comparer plusieurs approches :

- méthodes classiques de reconnaissance de formes,
- modèle supervisé (CNN maison),
- modèle pré-entraîné (transfer learning).

Problématique et démarche

Problématique : comment reconnaître des panneaux dans des images réelles qui présentent des variations de luminosité, de point de vue, d'occlusion et de bruit ?

Partie 1 : Présentation du jeu de données

1) Données

Le dataset GTSRB contient des images de panneaux réparties sur 43 classes. Dans notre exécution, le chargement donne :

- 26 640 images d'entraînement,
- 12 630 images de test,
- 43 classes.

Les images ont des tailles variables. On applique un redimensionnement en 32×32 pour l'apprentissage.

2) Split du jeu de données

Pour l'entraînement du CNN, on utilise :

- un split interne $\frac{90}{10}$ (train/validation) via `validation_split=0.1`.

3) Qualité et prétraitements

Voici les différents points relevés concernant la qualité du dataset :

- dataset réel, avec variations d'éclairage et de cadrage,
- classes déséquilibrées,
- présence de bruit et d'arrière-plans variables
- images pixellisées.



Fig. 1. – Exemple d'image pixelisee dans GTSRB.

Interpretation : on observe des contours en « marches d'escalier ». Cela signifie que l'image est composee de gros pixels visibles, ce qui rend les formes moins nettes et peut rendre la classification plus difficile.

Partie 2 : Methodes classiques de reconnaissance de formes

On teste une approche par segmentation de couleur (HSV) puis analyse des contours :

- masques pour les couleurs principales (rouge, jaune, bleu),
- morphologie mathematique pour nettoyer le masque,
- extraction de contour principal,
- signature de contour pour estimer la forme (cercle, triangle, octogone, autre).

Limites :

- sensible aux variations de couleur et d'eclairage,
- ne gere pas bien les panneaux complexes,
- methode utile pour une pre-classe grossiere mais pas suffisante pour 43 classes.

```
print(classification_report(y_test, pred_classic, target_names=[str(c) for c in classes]))
```

[15] ✓ 198m 23.5s Python

Approche classique - resultat test
accuracy=0.9608 | precision=0.9609 | recall=0.9608 | f1=0.9608
temps entrainement=11852.17s

	precision	recall	f1-score	support
00000	0.97	0.95	0.96	37
00001	0.92	0.94	0.93	375
00002	0.90	0.89	0.90	375
00003	0.94	0.93	0.94	240
00004	0.96	0.96	0.96	330
00005	0.87	0.86	0.87	315
00006	1.00	0.97	0.99	75
00007	0.94	0.93	0.94	240
00008	0.91	0.93	0.92	240
00009	0.98	0.95	0.96	248
00010	0.96	0.99	0.97	337
00011	0.97	0.98	0.97	225
00012	1.00	1.00	1.00	353
00013	1.00	0.99	1.00	360
00014	0.99	0.99	0.99	135
00015	0.99	0.98	0.99	105
00016	0.99	1.00	0.99	75
00017	0.99	1.00	1.00	188
00018	0.97	0.97	0.97	202
00019	0.97	1.00	0.99	38
...				
accuracy			0.96	6660
macro avg	0.97	0.97	0.97	6660
weighted avg	0.96	0.96	0.96	6660

Output is truncated. View as a scrollable element or open in a text editor. Adjust output settings...

Fig. 2. – Resultats de l'approche classique (descripteurs + SVM).

Interpretation : l'approche classique atteint une accuracy elevee (taux de bonnes predictions) et des scores precision/recall proches. Cela indique que, sur ce jeu local, les predictions sont globalement fiables et equilibrees.

Partie 3 : Methode supervisee (CNN maison)

1) Architecture

CNN simple avec :

- 3 blocs Conv2D + BatchNorm + ReLU + MaxPooling,
- Flatten,
- Dense(256) + Dropout,
- sortie softmax sur 43 classes.

2) Reglages

- Optimizer : Adam
- Learning rate initial : $1e-3$
- Batch : 64
- Epoques : 15 + fine-tuning 8 epoques
- EarlyStopping + ReduceLROnPlateau

3) Resultats

Sur GTSRB complet :

- accuracy (taux de bonnes predictions) test avant fine-tuning : 0.9146
- accuracy (taux de bonnes predictions) test apres fine-tuning : 0.9217

Le fine-tuning (learning rate plus faible) permet d'ameliorer legerement le score au-dela de 90%.

a) CNN sur GTSRB (captures)




Fig. 3. – Courbe d'accuracy du CNN sur GTSRB (entrainement vs validation).

Interpretation : la courbe de validation (donnees gardees pour evaluer pendant l'entrainement) monte vite et reste proche de la courbe d'entrainement. L'ecart reste limite, ce qui suggere peu de surapprentissage (overfitting : le modele memorise trop et generalise mal).



Fig. 4. – Exemples de predictions du CNN sur GTSRB.

Interpretation : la plupart des panneaux sont correctement classes. Quelques erreurs restent possibles sur des images floues ou peu contrastees, ce qui est attendu dans un jeu reel.

b) CNN maison sur dataset local




Fig. 5. – Courbes loss/accuracy du CNN maison (dataset local).

Interpretation : l'accuracy reste faible et progresse peu. Cela montre que le CNN maison n'arrive pas a apprendre des caracteristiques robustes avec ce petit jeu.




Fig. 6. – Matrice de confusion du CNN maison (dataset local).

Interpretation : la diagonale (bonnes predictions) est faible et beaucoup de valeurs sont hors diagonale. Cela signifie que le modele confond souvent les classes.

Partie 4 : Modele pre-entraine (transfer learning)

Un modele MobileNetV2 pre-entraine (ImageNet) est adapte au dataset. Principe :

- on geler les premieres couches,
- on entraine une tete de classification,
- on degeler partiellement pour affiner.

Cette approche est interessante car elle permet d'obtenir de bonnes performances avec moins de donnees, mais elle demande un ajustement fin des hyperparametres et du nombre de couches degelées.

Resultats (test) :

- accuracy (taux de bonnes predictions) : 0.8859
- precision (fiabilite des predictions positives) : 0.8905
- recall (taux de panneaux correctement retrouves) : 0.8859
- f1 (moyenne entre precision et recall) : 0.8863




Fig. 7. – Comparaison des scores F1 sur le dataset local.

Interpretation : le F1 (moyenne entre precision et recall) est plus eleve pour l'approche classique que pour le CNN maison, et le transfer learning se situe entre les deux. Cela indique que, sur peu de donnees, les methodes classiques restent tres competitives.

Partie 5 : Conclusion

- Les methodes classiques de formes sont utiles pour une detection grossiere, mais insuffisantes pour une classification fine.
- Le CNN maison atteint 0.9217 d'accuracy (taux de bonnes predictions) sur GTSRB apres fine-tuning.
- Le transfer learning est une alternative efficace, a condition de bien regler le fine-tuning.

Perspectives :

- augmenter les augmentations de donnees,
- tester un backbone plus puissant (ResNet, EfficientNet),
- sauvegarder les modeles (format .pth si implementation PyTorch, sinon .keras/.h5 pour TensorFlow).

Annexe : fichiers principaux

Projet/Projet_panneaux.ipynb

Rapports/DAGGAG_DOUBLET_APP5_EIE_TRAITEMENT_IMAGES_PROJET.typ